

화학 빅데이터 분석법

다섯 번째 수업

확률과 확률 분포

확률

- 수학적 확률: 가능한 모든 경우 중 관심 있는 경우의 비율
 - 예: 주사위를 두 개 던졌을 때 모두 홀수가 나올 확률 = $1/4$
- 통계적 확률: 전체 시행 횟수 중 특정 사건이 일어난 횟수의 비율
 - 예: 두 개의 주사위를 100번 던졌을 때 모두 홀수가 나올 확률

시행의 수가 무한히 늘어나면



통계적 확률 → 수학적 확률

- 예: 동전을 던져서 앞면이 나올 통계적 확률
 - 1회 던졌을 때: 앞 → 100%
 - 5회 던졌을 때: 앞앞뒤뒤앞 → $3/5 = 60\%$
 - 10회 던졌을 때: 뒤앞뒤뒤앞앞뒤앞뒤뒤 → $4/10 = 40\%$
 - 무한 번 던졌을 때: 50% (= 수학적 확률)

몬테카를로 시뮬레이션

- 충분히 많은 시행에 대해 통계적 확률은 수학적 확률에 근접
- 시뮬레이션을 통해 수학 공식을 적용하지 않고 확률을 계산
- 난수(random number): 무작위로 추출된 수
- Excel의 난수 함수
 - RAND(): 0과 1사이의 실수 난수 발생
 - RANDBETWEEN(a, b): a와 b 사이의 정수 난수 발생


원주율 구하기



확률분포

- **확률분포**: 확률이 어떻게 흩어져 있는지를 나타낸 것
- **이산 확률분포**: 결과값들이 띄엄띄엄 떨어져 있는 경우
 - 예: 주사위 굴리기, 선거 설문 조사, 분자의 분류
- **연속 확률분포**: 결과값들이 연속적으로 존재하는 경우
 - 예: 사람의 키, 어떤 지역의 기온, 용액의 pH

확률분포



대표적인 확률분포

- 이항 분포: 이산 확률분포

“동전을 n 번 던져서 앞면이 m 번 나올 확률”



Binomial

- 균등 분포: 이산/연속 확률분포



Continuous Uniform



Discrete Uniform

- 정규 분포: 연속 확률분포

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right]$$



Normal

중심 극한 정리

독립적으로 추출된, 충분히 큰 자료의
합이나 평균은 정규 분포를 따른다

정규 분포의 중요성!

확률분포를 따르는 데이터 만들기

- 이항 분포
 - 앞:뒤 = 0.5:0.5라면 `randbetween(a, b)` 활용
 - 앞:뒤 = $p:(1 - p)$ 라면 `rand()` 활용
- 균등 분포: 이산은 `randbetween(a, b)`, 연속은 `rand()`
- 정규 분포: `norm.inv(rand())`
- 그 외의 연속 분포: `xxx.inv(rand())` 형태로 이용