


화학 빅데이터 분석법

여섯 번째 수업

통계적 추론

모집단과 표본



통계적 추론

표본의 특성을 분석하여 모집단의 특성을 추론하는 과정

“표본의 정당 지지율이 A당 35%, B당 20%, C당 15%였다면
전국민의 정당 지지율은 얼마가 되겠는가?”

“표본의 pH가 6.7이었다면
실제 용액의 pH는 얼마가 되겠는가?”

표본 통계량

- 목표: 모집단의 평균, 분산, 표준편차를 추론
 - 표본을 무한 번 추출했을 때,
 - <표본 평균> → 모집단 평균
 - <표본 분산> → 모집단 분산
 - <표본 표준편차> → 모집단 표준편차
- 가 되도록 추론

표본 통계량

표본의 크기가 N 일 때,

- 표본 평균 $\langle x \rangle = \frac{1}{N} \sum_{i=1}^N x_i$
- 표본 분산 $s_x^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \langle x \rangle)^2$
 - 참고: 크기가 M 인 모집단의 분산 $\sigma_x^2 = \frac{1}{M} \sum_{i=1}^M (x_i - \langle x \rangle)^2$
- 표본 표준편차 $s_x = \sqrt{s_x^2}$
- Excel 명령어: AVERAGE(), VAR.S(), STDEV.S()

95% 신뢰 구간

- 모집단이 평균이 μ , 표준편차가 σ 인 분포를 따른다고 가정
- 크기 N 인 표본을 추출하여 표본 평균을 반복적으로 구하면 표본 평균의 분포는 평균이 μ , 표준편차가 $\sigma/\sqrt{N}$ 인 정규분포를 따름
- 추출한 표본의 평균을 $\langle x \rangle$ 라 하면 다음이 성립

$$P\left(\langle x \rangle - 2 \times \frac{\sigma}{\sqrt{N}} \leq \mu \leq \langle x \rangle + 2 \times \frac{\sigma}{\sqrt{N}}\right) \approx 0.95$$

표본 통계량만으로 예측하려면

$$P(\langle x \rangle - \varepsilon \leq \mu \leq \langle x \rangle + \varepsilon) \approx 1 - \alpha$$

- 표준오차 ε

$$\varepsilon = t(\alpha, N - 1) \frac{s_x}{\sqrt{N}}$$

- $t(\alpha, N - 1)$: Excel의 T.INV.2T($\alpha, N - 1$) 함수 이용

(혹은 뒷장의 표 참조)

$$(v = N - 1)$$

Number of degrees of freedom v	Maximum value of Student's t factor for the significance levels indicated			
	$t(v, 0.60)$	$t(v, 0.10)$	$t(v, 0.05)$	$t(v, 0.01)$
1	1.376	6.314	12.706	63.657
2	1.061	2.920	4.303	9.925
3	0.978	2.353	3.182	5.841
4	0.941	2.132	2.776	4.604
5	0.920	2.015	2.571	4.032
6	0.906	1.943	2.447	3.707
7	0.896	1.895	2.365	3.499
8	0.889	1.860	2.306	3.355
9	0.883	1.833	2.262	3.250
10	0.879	1.812	2.228	3.169
11	0.876	1.796	2.201	3.106
12	0.873	1.782	2.179	3.055
13	0.870	1.771	2.160	3.012
14	0.868	1.761	2.145	2.977
15	0.866	1.753	2.131	2.947
16	0.865	1.746	2.120	2.921
17	0.863	1.740	2.110	2.898
18	0.862	1.734	2.101	2.878
19	0.861	1.729	2.093	2.861
20	0.860	1.725	2.086	2.845
21	0.859	1.721	2.080	2.831
22	0.858	1.717	2.074	2.819
23	0.858	1.714	2.069	2.807
24	0.857	1.711	2.064	2.797
25	0.856	1.708	2.060	2.787
26	0.856	1.706	2.056	2.479
27	0.855	1.703	2.052	2.771
28	0.855	1.701	2.048	2.763
29	0.854	1.699	2.045	2.756
30	0.854	1.697	2.042	2.750
40	0.851	1.684	2.021	2.704
60	0.848	1.671	2.000	2.660
∞	0.842	1.645	1.960	2.576



예제

다음 측정 온도에 대한 95% 신뢰 구간을 결정하시오.

42.70°C, 42.60°C, 42.78°C, 42.83°C

$$\langle x \rangle - \varepsilon \leq x \leq \langle x \rangle + \varepsilon; \quad \varepsilon = t(N - 1, \alpha) \frac{s_x}{\sqrt{N}}$$

$$\langle x \rangle = 42.73^\circ\text{C}$$

$$s_x^2 = 0.0101^\circ\text{C}^2$$

$$s_x = 0.10^\circ\text{C}$$

$$\varepsilon = t(3, 0.05) \frac{s_x}{\sqrt{N}} = 3.182 \times \frac{0.10^\circ\text{C}}{\sqrt{4}} = 0.16^\circ\text{C}$$

따라서, 95% 신뢰 구간은 $x = 42.73^\circ\text{C} \pm 0.16^\circ\text{C}$ 으로 구할 수 있다.

가설 검정

모집단의 특징에 대한 **가설(영 가설)**을 세워놓고
관측된 표본의 특징을 볼 때 그 **가설이 참일 가능성**을 계산

“표본의 신장 평균이 175 cm이었다면
전국민의 신장 평균이 180 cm라는 가설은 그럴싸한가?”

영 가설의 예

- 데이터 모집단의 평균은 특정 값을 갖는다.
- 두 표본 데이터는 같은 모집단에서 나왔다.
- 데이터 모집단의 두 변수는 서로 비례하는 관계에 있다.

⋮

검정 통계량

- 가설 검정을 위해 주어진 데이터를 요약한 통계량
- 이 통계량을 기준값과 비교하여 가설 검정을 수행한다.

예제

- 신뢰 구간을 구하는 식(여기서 μ 는 미지수)

$$P(\langle x \rangle - \varepsilon \leq \mu \leq \langle x \rangle + \varepsilon) \approx 1 - \alpha$$

$$\varepsilon = t(\alpha, N - 1) \frac{s_x}{\sqrt{N}}$$

$$P(|\langle x \rangle - \mu| \leq \varepsilon) \approx 1 - \alpha$$

$$P\left(|\langle x \rangle - \mu| \frac{\sqrt{N}}{s_x} \leq t(\alpha, N - 1)\right) \approx 1 - \alpha$$

예제

$$P\left(|\langle x \rangle - \mu| \frac{\sqrt{N}}{s_x} \leq t(\alpha, N - 1)\right) \approx 1 - \alpha$$

- 영 가설: 데이터 모집단의 평균은 특정 값 μ_0 를 갖는다.

$$\text{검정 통계량 } T = |\langle x \rangle - \mu_0| \frac{\sqrt{N}}{s_x}$$

$T \leq t(\alpha, N - 1)$ 라면 유의 수준 α 에서 영 가설 수용

$T > t(\alpha, N - 1)$ 라면 유의 수준 α 에서 영 가설 기각

몇 가지 검정

- 표본 평균에 대한 검정: t 검정
- 표본 표준편차에 대한 검정: F 검정
- 특이점 검정
 - Q 검정
 - Grubbs 검정

t 검정

1. 단일 표본 t 검정: 데이터의 평균이 특정 값과 일치하는가?
2. 대응 표본 t 검정: 짝을 이루는 두 데이터의 평균이 서로 일치하는가?
3. 독립 표본 t 검정: 두 데이터의 평균이 서로 일치하는가?

단일 표본 t 검정

“데이터의 평균이 특정 값과 일치하는가?”

- 주어진 데이터로부터 신뢰 구간을 계산하여 특정 값이 포함되는지 확인

$$\langle x \rangle - \varepsilon \leq \mu \leq \langle x \rangle + \varepsilon, \quad \varepsilon = t(\alpha, N - 1) s_x / \sqrt{N}$$

- 검정 통계량을 계산하여 유의 수준에 맞는 기준값보다 작은지 확인

$$|\langle x \rangle - \mu_0| \sqrt{N} / s_x \leq t(\alpha, N - 1)$$

대응 표본 t 검정

“짝을 이루는 두 데이터의 평균이 서로 일치하는가?”

$w_i = x_i - y_i$ 를 정의하고,

이 데이터의 평균이 0이 되는지 단일 표본 t 검정을 수행한다.

$$|\langle w \rangle| \frac{\sqrt{N}}{s_w} \leq t(\alpha, N - 1)$$

독립 표본 t 검정

“두 데이터의 평균이 서로 일치하는가?”

- 두 데이터의 표준편차가 같은 경우($\sigma_x^2 = \sigma_y^2$)

$$|\langle x \rangle - \langle y \rangle| \sqrt{\frac{N_x + N_y - 2}{(N_x - 1)s_x^2 + (N_y - 1)s_y^2} \cdot \frac{N_x N_y}{N_x + N_y}} \leq t(\alpha, N_x + N_y - 2)$$

- 두 데이터의 표준편차가 다른 경우($\sigma_x^2 \neq \sigma_y^2, N_x, N_y \gg 1$)

$$\frac{|\langle x \rangle - \langle y \rangle|}{\sqrt{s_x^2/N_x + s_y^2/N_y}} \leq t\left(\alpha, \frac{(s_x^2/N_x + s_y^2/N_y)^2}{(s_x^2/N_x)^2/(N_x - 1) + (s_y^2/N_y)^2/(N_y - 1)}\right)$$

F 검정


1. 단일 표본 F 검정: 데이터의 표준편차가 특정 값 σ_0 와 일치하는가?

$$\frac{(N - 1)s_x^2}{\sigma_0^2} \leq \chi^2(\alpha, N - 1)$$

2. 2표본 F 검정: 두 데이터의 표준편차가 서로 일치하는가?

$$\frac{s_x^2}{s_y^2} \leq F(\alpha, N_x - 1, N_y - 1)$$

특이점(outlier)



특이점 검정

- Dixon의 Q 검정

$$\frac{|x_{\text{target}} - x_{\text{nearest}}|}{x_{\text{max}} - x_{\text{min}}} \leq Q(\alpha, N)$$

- Grubbs 검정

$$\frac{|x_{\text{target}} - \langle x \rangle|}{s_x} \leq G(\alpha, N)$$

기준값 표($\alpha = 0.05$)

N	$Q(0.05, N)$	$G(0.05, N)$
3	0.97	1.15
4	0.84	1.46
5	0.72	1.67
6	0.63	1.82
7	0.58	1.94
8	0.53	2.03
9	0.50	2.11
10	0.47	2.18
20	0.36	2.56
30	0.30	2.75