

화학 빅데이터 분석법

일곱 번째 수업

상관 분석과 회귀 분석

중간고사 안내


- 일시: 4월 25일(화) 오후 12:00-1:00
- 장소: 화학관 112호(홀수 학번), 114호(짝수 학번)
- 범위: 4강-7강(개념 + 통계 계산)
- 신분증 지참(모바일 학생증도 가능)
- 계산기 지참

상관 분석과 회귀 분석

- 상관 분석: 변수들 사이 관련성의 정도를 파악
- 회귀 분석: 변수들 사이 함수적인 관계를 파악

상관 계수

두 변수 사이의 통계적 상관 관계를 정량화한 수치



(그림 출처: https://www.wikiwand.com/en/Correlation_and_dependence)

상관 계수의 정의

$$r = \frac{NS_{xy} - S_x S_y}{[(NS_{x^2} - S_x^2)(NS_{y^2} - S_y^2)]^{1/2}}$$


이 때,

$$S_x = \sum_{i=1}^N x_i, \quad S_y = \sum_{i=1}^N y_i$$

$$S_{x^2} = \sum_{i=1}^N x_i^2, \quad S_{xy} = \sum_{i=1}^N x_i y_i, \quad S_{y^2} = \sum_{i=1}^N y_i^2$$

회귀 분석

- **선형 회귀**: 두 변수 사이의 관계가 선형
 - 단순 선형 회귀: 독립변수가 하나인 경우
- **비선형 회귀**: 두 변수 사이의 관계가 비선형



(그림 출처: https://commons.wikimedia.org/wiki/File:Normdist_regression.png)

단순 선형 회귀 분석

- 데이터: x_i 와 y_i
- x_i 로부터 다음과 같이 y_i 의 예측값을 계산

$$\hat{y}_i = \alpha + \beta x_i$$

- 잔차 $\epsilon_i = y_i - \hat{y}_i$: 예측의 오차
- **최소 제곱법**: $\sum_i \epsilon_i^2$ 를 최소화하는 α 와 β 를 찾음
- 이 때 수학적으로 α 와 β 를 구하는 수식이 존재

단순 선형 회귀 분석

$$E = \sum_i \epsilon_i^2 = \sum_i (y_i - \alpha - \beta x_i)^2$$





최솟값을 구하기 위해

$$\frac{\partial E}{\partial \alpha} = \frac{\partial E}{\partial \beta} = 0$$

이 조건을 정리하면 다음과 같은 식을 얻을 수 있다.

$$\alpha = \frac{S_{x^2}S_y - S_xS_{xy}}{NS_{x^2} - S_x^2}, \quad \beta = \frac{NS_{xy} - S_xS_y}{NS_{x^2} - S_x^2}$$

선형 회귀법의 적용과 한계



(그림 출처: https://commons.wikimedia.org/wiki/File:Anscombe%27s_quartet_3.svg)

Excel 명령어

- 상관 계수 CORREL(X, Y)
- 선형 회귀
 - 기울기 SLOPE(X, Y)
 - 절편 INTERCEPT(X, Y)